ShopPulse — Tổng quan dự án & phân công 5 người

Oct 5, 2026 · @Bỳnh

1. Tóm tắt dự án

ShopPulse là nền tảng phân tích hành vi khách hàng và gợi ý sản phẩm thời gian thực cho sàn thương mại điện tử, xây theo kiến trúc Lambda trên Kubernetes. BTL môn Lưu trữ & Xử lý Dữ liệu lớn (IT4931), 5 thành viên, 12 tuần từ 28/9 đến 20/12/2026, mỗi tuần kết thúc bằng 1 tag release trên GitHub.

Hệ thống nhận luồng sự kiện xem/thêm giỏ/mua (285 triệu sự kiện thật của REES46), tính KPI theo phút, phát hiện bỏ giỏ và bot, gợi ý sản phẩm bằng Spark MLlib, và đối soát kết quả speed layer với batch layer bằng số liệu.

Hạng mục	Nội dung
Đề tài	Phân tích hành vi khách hàng & gợi ý sản phẩm realtime cho TMĐT
Kiến trúc	Lambda (batch + speed + serving) trên cụm k3s nhiều laptop
Dữ liệu	REES46 eCommerce (285 triệu sự kiện, 10/2019–4/2020) + lịch khuyến mãi tự sinh (PostgreSQL) + replayer bơm lõi vào Kafka
Công nghệ chính	Kafka 4.0 KRaft (Strimzi), HDFS 3.4, Spark 3.5.7 + Java 17, Cassandra 4.1, Redis, Trino + Hive Metastore, Airflow, Prometheus/Grafana, Superset, FastAPI
Thời gian	12 tuần, 28/9–20/12/2026; demo giữa kỳ tuần 6; bảo vệ tuần 12
Khối lượng	khoảng 73–82 giờ/người trong 12 tuần (4–8 giờ/tuần)

Tình hình hiện tại (5/10): tuần 1 vừa kết thúc, hôm nay bắt đầu tuần 2. Mã nguồn tham chiếu đã có trong thư mục `Big Data/shoppulse` trên máy Bình (220 file, 39 test xanh, pipeline chạy thử local trên dữ liệu mẫu). Việc còn lại: đưa code vào repo nhóm theo từng tuần, dựng cụm K8s, chạy trên dữ liệu thật, đo benchmark/chaos, viết báo cáo và slide.

Thay đổi so với kế hoạch 4 người cũ: vai Speed & Serving được tách đôi. TV3 chỉ giữ Speed layer (Spark Structured Streaming); TV5 mới nhận Serving & Quan sát (Cassandra, Redis, Trino view, Superset, API, Grafana, khung test). Một số việc của TV4 (API, Superset, khung pytest) chuyển sang TV5 để cân giờ.

Lưu ý về commit: vì code đã có sẵn, mỗi người tự đưa phần thuộc mảng mình vào repo đúng tuần được giao, sau khi đọc hiểu, chạy được trên cụm, sửa cho hợp cấu hình thật và thêm số đo. Không commit hộ người khác (thầy xem biểu đồ Contributors theo tác giả), không đẩy cả 220 file trong một lần. Nếu môn có quy định về dùng công cụ AI, nhóm nên ghi rõ trong báo cáo.

2. Bài toán và dữ liệu

ShopPulse trả lời 8 câu hỏi kinh doanh, chia theo hai lớp của Lambda; mỗi câu có dashboard hoặc API riêng.

#	Câu hỏi kinh doanh	Lớp	Người phụ trách chính
1	Mỗi phút có bao nhiêu lượt xem, thêm giỏ, mua, doanh thu, tỉ lệ chuyển đổi theo danh mục?	Speed	TV3
2	Sản phẩm nào đang hot trong 10 phút gần nhất?	Speed	TV3
3	Phiên nào bỏ giỏ (thêm giỏ, 30 phút không mua)?	Speed	TV3
4	Tài khoản nào có hành vi giống bot?	Speed	TV3
5	Phiên đang diễn ra có khả năng mua bao nhiêu %?	Speed + ML	TV4 + TV3
6	Gợi ý sản phẩm nào cho từng user; sản phẩm nào hay được xem cùng nhau?	Batch + ML + Graph	TV4
7	Khách hàng chia thành những nhóm nào (RFM), phễu rơi ở đâu?	Batch	TV2 + TV4
8	Doanh thu từng danh mục ngày mai dự báo bao nhiêu, ngày nào bất thường?	Batch + time series	TV4

Ba nguồn dữ liệu:

- **Sự kiện hành vi** — REES46 eCommerce behavior data: 285 triệu sự kiện, 9 cột (event_time, event_type, product_id, category_id, category_code, brand, price, user_id, user_session). Riêng 10–11/2019 đã khoảng 110 triệu dòng, 14,8 GB CSV.
- **Lịch khuyến mãi / flash sale** — nhóm tự sinh, lưu PostgreSQL, kéo vào băng Spark JDBC (thay Sqoop).
- **Luồng realtime** — replayer đọc sự kiện theo thời gian, đẩy vào Kafka với tốc độ tuỳ chỉnh, có chế độ bơm lỗi (trùng, trễ, sai thứ tự, bùng nổ flash sale).

Vì sao là Big Data (5V):

V	Số liệu trong dự án
Volume	285 triệu sự kiện, 7 file nén 1,6–2,7 GB/tháng; không nạp nổi vào pandas trên máy 16 GB RAM
Velocity	Trung bình ~26 sự kiện/giây; phát lại x60 ≈ 1.560/giây; mô phỏng flash sale x10 ≈ 15.600/giây
Variety	Sự kiện Avro, danh mục phân cấp, bảng quan hệ PostgreSQL, đồ thị sản phẩm, mô hình ML
Veracity	brand/category_code thiếu nhiều, giá bằng 0, bot, sự kiện trùng và trễ (có chủ đích bơm vào)
Value	8 câu hỏi kinh doanh ở trên

Giới hạn ghi rõ trong báo cáo: dữ liệu của sàn nước ngoài 2019–2020; luồng là phát lại chứ không phải traffic thật; cụm chạy trên laptop nên số đo hiệu năng mang tính tương đối.

Kết quả đầu ra và giá trị của dự án

Mỗi câu hỏi cho ra một sản phẩm cụ thể (dashboard, danh sách, API) để sàn TMĐT ra quyết định nhanh và đúng hơn. Bảng dưới mô tả dạng câu trả lời; con số cụ thể có sau khi chạy trên dữ liệu thật.

#	Câu hỏi	Hệ thống trả ra	Giải quyết vấn đề gì
1	KPI mỗi phút	Biểu đồ cập nhật mỗi phút: lượt xem, thêm giỏ, mua, doanh thu, tỉ lệ chuyển đổi theo danh mục (Grafana)	Vận hành thấy sự cố trong flash sale sau vài phút (ví dụ một danh mục tụt doanh thu đột ngột), không phải chờ báo cáo hôm sau

#	Câu hỏi	Hệ thống trả ra	Giải quyết vấn đề gì
2	Sản phẩm hot 10 phút	Top-10 sản phẩm đang tăng mạnh, làm mới mỗi phút (Redis)	Mục "Đang thịnh hành" trên trang chủ; cảnh báo hàng sắp cháy để nhập thêm
3	Phiên bỏ giỏ	Cảnh báo gửi ra Kafka 30 phút sau khi bỏ dở: user, phiên, sản phẩm trong giỏ, giá trị	Marketing gửi voucher nhắc giỏ đúng lúc, gỡ lại một phần doanh thu bị mất
4	Tài khoản giống bot	Danh sách tài khoản có lượt xem bất thường trong 10 giây, kèm mức độ	Chặn cào giá, chống gian lận; loại bot khỏi số liệu để KPI không bị phồng
5	Khả năng mua của phiên đang mở	Điểm 0–100% cho từng phiên đang diễn ra (model GBT, đo bằng AUC)	CSKH/chatbot ưu tiên khách sắp mua; tung ưu đãi đúng người thay vì đại trà
6	Gợi ý cho từng user, sản phẩm xem cùng	API trả top-N sản phẩm cho mỗi user (ALS, NDCG@10 so với baseline); danh sách "khách cũng xem"; cụm sản phẩm từ đồ thị (PageRank)	Mục "Có thể bạn thích", tăng giá trị đơn hàng; xếp sản phẩm liên quan cạnh nhau
7	Phân khúc khách hàng, phễu	Nhóm khách theo RFM/KMeans (trung thành, sắp rời bỏ, mới…); phễu xem → giỏ → mua, rơi nhiều nhất ở bước nào, theo danh mục và khung giờ	CRM chăm sóc từng nhóm khác nhau; biết cần sửa khâu nào trong phễu
8	Dự báo doanh thu, ngày bất thường	Doanh thu dự báo ngày mai từng danh mục (sai số WAPE); danh sách ngày bất thường (z-score)	Kế hoạch kho và tài chính; phát hiện sự cố hoặc chiến dịch hiệu quả bất ngờ

Về phía doanh nghiệp, dự án giải quyết 3 việc:

- **Thấy ngay chuyện đang xảy ra** (câu 1–4): số liệu trễ vài giây thay vì báo cáo cuối ngày, nên phản ứng được trong flash sale.
- **Cá nhân hoá** (câu 5–6): mỗi khách thấy gợi ý và ưu đãi riêng thay vì cùng một trang chủ.
- **Hiểu khách và lập kế hoạch** (câu 7–8): biết ai là khách giá trị, khâu nào làm mất khách, tuần sau cần bao nhiêu hàng.

Về phía môn học (phần thầy chấm), dự án chứng minh bằng số đo rằng hệ thống xử lý dữ liệu lớn đúng và bền:

- **Đúng:** bảng đối soát cho thấy doanh thu speed layer lệch bao nhiêu % so với batch; đếm khớp 100% sau khi cố tình làm sập driver (exactly-once).
- **Bền:** tắt một broker Kafka, một DataNode, một node Cassandra mà hệ thống vẫn chạy, không mất dữ liệu.
- **Nhanh và mở rộng được:** bảng benchmark trước/sau tối ưu (join, partition, cache) và thời gian chạy khi tăng executor hoặc tăng dữ liệu.
- **Thực tế:** dữ liệu bẩn (trùng, trễ, bot, giá bằng 0) được xử lý có kiểm soát và đo được bao nhiêu % bị loại.

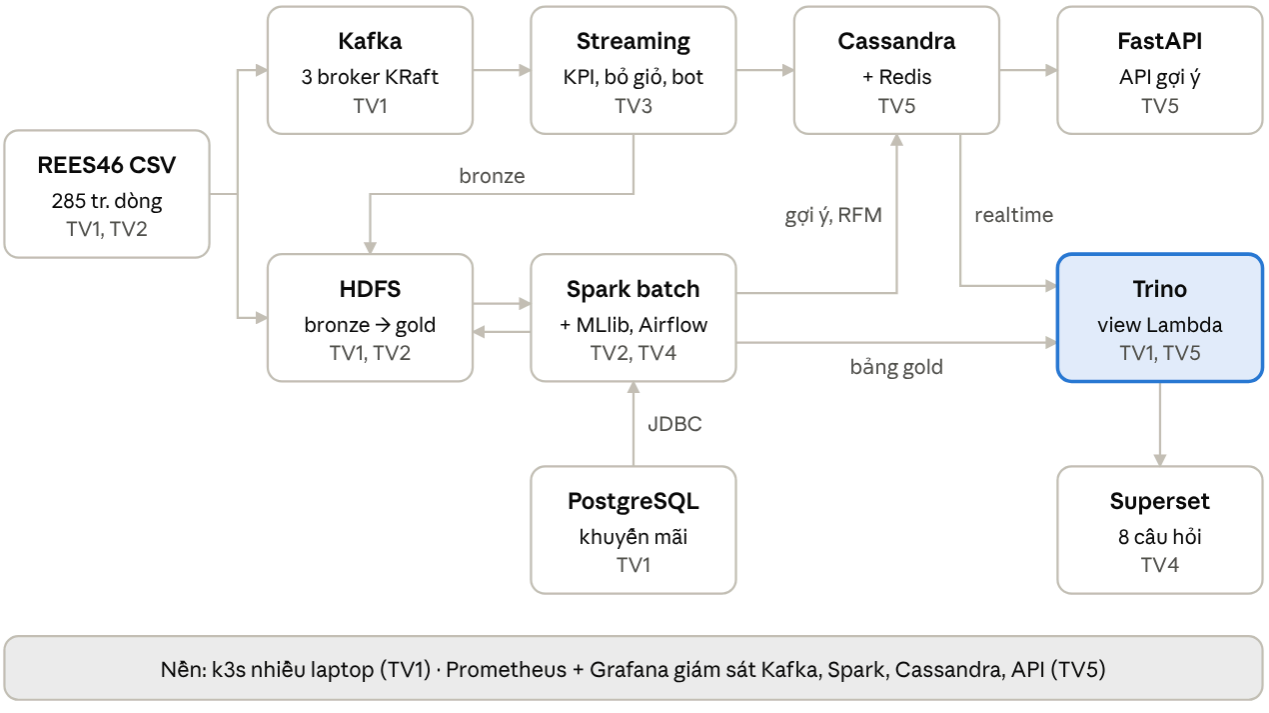
Vì dữ liệu là của sàn nước ngoài 2019–2020 và luồng là phát lại, kết quả kinh doanh mang tính minh hoạ cho phương pháp. Giá trị thật nằm ở pipeline: thay dữ liệu của một sàn Việt Nam vào là chạy được.

3. Kiến trúc Lambda trên Kubernetes

Cùng một luồng sự kiện đi hai đường: speed layer cho số liệu trong vài giây, batch layer tính lại chính xác mỗi đêm; Trino hợp nhất hai view để dashboard vừa mới vừa đúng.

Một luồng sự kiện đi hai đường, gặp nhau ở Trino

Hàng trên: speed layer · hàng giữa: batch layer · dòng cuối mỗi khối: người phụ trách



Kiến trúc Lambda của ShopPulse · người phụ trách từng khối

Replayer (TV1) phát lại CSV vào Kafka cho speed layer; `csv_to_parquet` (TV2) nạp lịch sử vào HDFS cho batch layer. Trino ghép bảng gold với số liệu realtime trong Cassandra thành view Lambda.

Thành phần	Công nghệ	Vai trò trong dự án	Chủ sở hữu
Hạ tầng	k3s nhiều laptop nối qua Tailscale (dự phòng: kind 1 máy)	Chạy toàn bộ dịch vụ; demo rút mạng 1 node	TV1
Message queue	Kafka 3 broker KRaft qua Strimzi, Avro	Topic `events` 6 partition, key = user_id, RF=3, min.insync=2, acks=all, producer idempotent	TV1
Lưu trữ phân tán	HDFS 1 NameNode + 3 DataNode, Parquet + Snappy	Data lake bronze/silver/gold, partition theo ngày, bucket theo user_id	TV1 (triển khai), TV2 (dữ liệu)
Xử lý batch	PySpark 3.5 trên K8s qua Spark Operator	Làm sạch, tổng hợp, join, tối ưu	TV2
Xử lý stream	Spark Structured Streaming	KPI cửa sổ, watermark, sessionization có trạng thái, exactly-once	TV3
ML & đồ thị	Spark MLlib, GraphFrames	ALS, GBT, KMeans, PageRank, dự báo chuỗi thời gian	TV4
NoSQL	Cassandra 3 node + Redis	Cassandra: view phục vụ query-first; Redis: top-K, bộ đệm nóng	TV5
SQL engine	Trino + Hive Metastore	Truy vấn liên nguồn HDFS + Cassandra, view Lambda hợp nhất	TV1 (triển khai), TV5 (view)
Điều phối	Apache Airflow	DAG hằng đêm: silver → gold → train → đối soát	TV1 (triển khai), TV2 (DAG)
Hiển thị & API	Superset, Grafana, FastAPI	Dashboard kinh doanh, dashboard kỹ thuật, API gợi ý	TV4 (Superset), TV5 (Grafana, API)
Giám sát	Prometheus + Grafana, Kafka exporter, Spark metrics	Consumer lag, thông lượng, độ trễ, cảnh báo	TV5

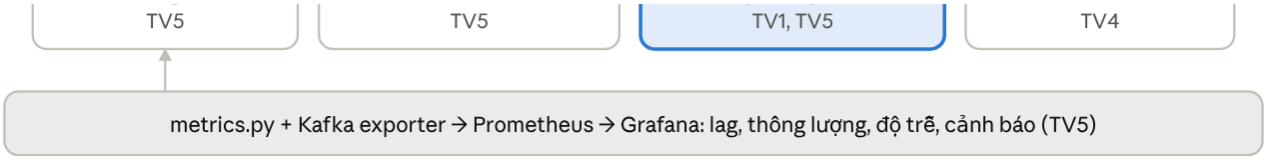
Toàn bộ stack cần khoảng 14–16 GB RAM, nên cụm chính ghép 2–3 laptop thành k3s (mỗi máy 1 node); dự phòng là bật/tắt Airflow, Superset theo nhu cầu trên kind 1 máy.

Sơ đồ luồng dữ liệu

Sự kiện chạy song song qua speed và batch, gặp lại ở lớp phục vụ

Tên file là job trong repo · mũi tên là hướng dữ liệu · nét đứt: model nạp vào stream





Sơ đồ luồng dữ liệu · từ nguồn đến dashboard, theo từng job

1. **Thu nhận:** replayer đọc CSV theo thời gian, bơm lỗi (trùng, trễ, sai thứ tự, flash sale) rồi đẩy vào topic `events`; song song, `csv_to_parquet.py` nạp dữ liệu lịch sử thẳng vào HDFS bronze.
2. **Speed layer (vài giây):** 4 job streaming cùng đọc `events`. `bronze_sink.py` ghi sự kiện thô xuống HDFS; ba job còn lại tính KPI, trending, phiên và ghi vào Cassandra, Redis, topic `alerts`.
3. **Batch layer (mỗi đêm, Airflow):** bronze → silver → gold → train model → đối soát → đẩy kết quả sang Cassandra. Model GBT được nạp ngược vào `sessions.py` để chấm điểm phiên đang mở.
4. **Phục vụ:** Trino ghép bảng gold (đến hôm qua) với số liệu realtime (hôm nay) thành view Lambda cho Superset; FastAPI đọc gợi ý từ Cassandra; Grafana hiển thị realtime và giám sát.

4. Phân vai 5 thành viên

Chia theo lớp kiến trúc, mỗi người sở hữu một mảng code riêng nên commit hằng tuần không chồng lên nhau. Ai cũng viết Spark và ai cũng phải chạy được toàn hệ thống, để khi bảo vệ thầy hỏi bất kỳ ai cũng trả lời được. Điền tên thật vào cột "Thành viên".

Vai	Thành viên	Hợp với người	Sở hữu (thư mục trong repo)	Spark riêng	Lessons learned	Tổng giờ (12 tuần)
TV1 — Platform & Ingestion (nhóm trưởng kỹ thuật)	(điền)	Mạnh Linux, Docker, mạng	`infra/` (k3s, Kafka, HDFS, PostgreSQL, Hive Metastore, Trino, Airflow, Superset, security), `.github/`, `ingestion/replayer.py`, `ingestion/chaos.py`, `ingestion/promotions.py`, `mapreduce/`	Nạp JDBC song song, MapReduce vs Spark, benchmark định dạng file	01 Ingestion, 05 Integration, 10 Security	80
TV2 — Batch Layer	(điền)	Mạnh SQL, tư duy dữ liệu	`shoppulse/` (config, spark, schemas, quality, udfs), `ingestion/csv_to_parquet.py`, `batch/`, `airflow/dags/`	Silver/gold, window, pivot, UDF/UDAF, các loại join, tối ưu, scaling	02 Spark, 04 Storage, 06 Performance	82

Vai	Thành viên	Hợp với người	Sở hữu (thư mục trong repo)	Spark riêng	Lessons learned	Tổng giờ (12 tuần)
TV3 — Speed Layer	(điền)	Mạnh lập trình hệ thống	`streaming/`, `infra/docker/spark/`, `infra/k8s/spark/`	KPI cửa sổ, watermark, sessionization có trạng thái, exactly-once, chấm điểm realtime	03 Stream, 11 Fault Tolerance	76
TV4 — ML & Analytics	(điền)	Mạnh toán, ML	`ml/`, `dashboards/superset/`, `benchmarks/report.py`, `docs/eda.md`, `docs/results.md`	ALS, GBT pipeline, KMeans, GraphFrames, thống kê, time series	08 Scaling	74
TV5 — Serving, Giám sát & Kiểm thử	(điền)	Cẩn thận, thích backend/DevOps	`serving/` (Cassandra, Trino view, API), `infra/k8s/cassandra`, `redis`, `monitoring`, `api`, `dashboards/grafana/`, `tests/` (khung), `docs/chaos.md`	Export gold sang Cassandra, view Lambda/đối soát, load test API	07 Monitoring, 09 Data Quality & Testing	73

Quy tắc giữ công bằng:

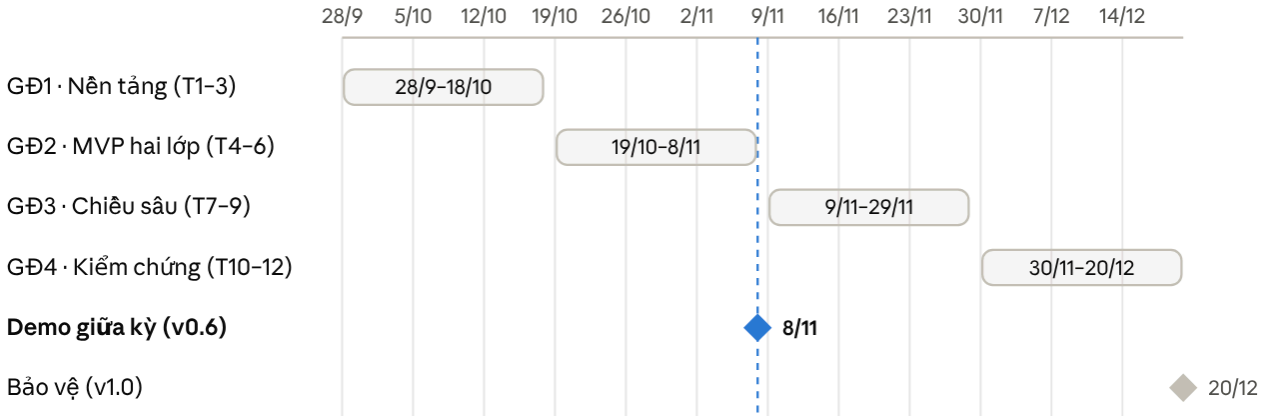
- TV1 nặng ở tuần 1–4 (dựng hạ tầng), TV4 nặng ở tuần 4–8 (ML); kế hoạch tuần đã bù trừ: TV3, TV4, TV5 mỗi người tự dựng 1 thành phần hạ tầng ở tuần 2 (Spark Operator, HDFS, Cassandra/Redis).
- Mỗi PR có 1 người khác review; cặp review xoay vòng mỗi tuần (bảng ở mục 6) để ai cũng đọc code của cả 4 người còn lại.
- Scrum master xoay vòng: tuần 1 TV1, tuần 2 TV2, …, tuần 6 lại TV1. Người này chủ trì họp, viết báo cáo tuần, gắn tag release.
- Không ai có tuần 0 commit; mỗi người tối thiểu 2 PR/tuần.
- Cặp dự phòng khi một người chậm: TV1↔TV5 (hạ tầng/serving), TV2↔TV4 (Spark batch/ML), TV3↔TV5 (streaming/serving).

5. Timeline 12 tuần

Dự án chia 4 giai đoạn; mốc quan trọng nhất là demo end-to-end giữa kỳ ở tuần 6, vì 6 tuần sau dành cho chiều sâu (số đo, chaos test, báo cáo). Việc cụ thể của từng người, file và commit gợi ý năm ở tab "Kế hoạch từng tuần".

Demo giữa kỳ 8/11 chia đôi 12 tuần; bảo vệ 20/12

4 giai đoạn, mỗi tuần 1 tag release; hôm nay 5/10 là đầu tuần 2



Lộ trình 12 tuần · 4 giai đoạn, 2 mốc

Tuần	Thời gian	Mục tiêu	Tag	Scrum master	Hoàn thành khi
1	28/9–4/10	Khởi động, đề xuất, khung repo	v0.1-proposal	TV1	Proposal, sơ đồ, 5 ADR, CI xanh; k3s ≥ 2 node Ready
2	5/10–11/10	Hạ tầng lõi trên K8s	v0.2-infra	TV2	Kafka ISR = 3; HDFS 3 DataNode live; Cassandra 3 node UN; SparkPi chạy
3	12/10–18/10	Luồng dữ liệu đầu-cuối đầu tiên	v0.3-pipeline	TV3	Video 2 phút replayer → Kafka → HDFS; ≥ 15 test xanh trên CI
4	19/10–25/10	Batch v1 + Speed v1	v0.4-layers	TV4	Trino đếm được bảng events; đủ bảng gold; KPI phút vào Cassandra; có ml_als.json
5	26/10–1/11	Tối ưu batch, streaming nâng cao, bơm lỗi	v0.5-optimize	TV5	optimization.json + plan; MapReduce khớp Spark; trending trong Redis; Prometheus chạy
6	2/11–8/11	Stateful + Graph — **DEMO GIỮA KỲ**	v0.6-midterm	TV1	Demo end-to-end 5 phút; báo cáo giữa kỳ; DAG Airflow xanh
7	9/11–15/11	Serving Lambda + phân tích nâng cao	v0.7-serving	TV2	View Lambda trên Trino có dữ liệu cả 2 lớp; reconciliation.json; 3 file kết quả ML
8	16/11–22/11	Bảo mật, API, kiểm thử	v0.8-secure	TV3	Truy cập trái phép bị chặn (ảnh log); API gợi ý chạy trên cụm; ≥ 35 test xanh
9	23/11–29/11	Thí nghiệm hiệu năng & mở rộng	v0.9-bench	TV4	docs/benchmarks.md có bảng + biểu đồ cho 6 thí nghiệm
10	30/11–6/12	Chaos test, chứng minh chịu lỗi	v0.10-chaos	TV5	docs/chaos.md đủ 5 kịch bản + video 3 phút

Tuần	Thời gian	Mục tiêu	Tag	Scrum master	Hoàn thành khi
11	7/12–13/12	Chạy toàn bộ dữ liệu, viết báo cáo	v0.11-rc	TV1	Báo cáo nháp đủ 4 phần + 11 lessons có số liệu
12	14/12–20/12	Hoàn thiện & bảo vệ	v1.0	TV2	Tập dượt 2 lần; release gồm báo cáo PDF, slide, video

Nếu tuần 1 chưa xong, làm bù trong 2 ngày đầu tuần 2 và ghi rõ trong báo cáo tuần. Nếu học kỳ thực tế ngắn hơn, gộp tuần 9 và 10 trước.

6. Quy trình commit hằng tuần

Thầy nhìn tiến độ qua 4 thứ: tag release mỗi tuần, file báo cáo tuần, board công việc, và biểu đồ commit của từng người. Hạn chốt mỗi tuần: tối Chủ nhật.

Nhịp mỗi tuần:

1. **Thứ Hai** — họp 30 phút; scrum master tạo Milestone `Week NN`; mỗi dòng trong tab "Kế hoạch từng tuần" thành 1 Issue có người nhận và ước lượng giờ.
2. **Thứ Hai – Thứ Năm** — mỗi Issue một nhánh `feat/<vai>-<việc>` (ví dụ `feat/tv3-kpi-minute`); commit nhỏ, nhiều lần trong tuần, không dồn vào tối Chủ nhật.
3. **Thứ Năm** — kiểm tra nhanh trên nhóm chat; việc nào trượt thì ghi lý do và chuyển sang tuần sau ngay.
4. **Thứ Sáu – Thứ Bảy** — mở PR vào `main`, người review theo bảng dưới; CI phải xanh mới merge.
5. **Chủ nhật** — mỗi người điền dòng của mình trong `docs/weekly/week-NN.md`; scrum master merge, gắn tag, tạo Release kèm ảnh chụp hoặc video ngắn.

Quy ước commit (Conventional Commits): `<loại>(<phạm vi>): <mô tả>` — loại: `feat`, `fix`, `test`, `docs`, `ci`, `chore`, `perf`, `refactor`; phạm vi: `infra`, `kafka`, `hdfs`, `ingestion`, `batch`, `streaming`, `ml`, `serving`, `api`, `monitoring`, `tests`, `report`. Ví dụ: `feat(streaming): add 10-minute watermark to kpi_minute`. Mỗi người cấu hình `git config user.name` và `user.email` trùng email GitHub, nếu không commit sẽ không được tính vào biểu đồ Contributors.

Cặp review xoay vòng (lặp lại mỗi 4 tuần):

Tuần	TV1 review	TV2 review	TV3 review	TV4 review	TV5 review
1, 5, 9	TV2	TV3	TV4	TV5	TV1
2, 6, 10	TV3	TV4	TV5	TV1	TV2
3, 7, 11	TV4	TV5	TV1	TV2	TV3

Tuần	TV1 review	TV2 review	TV3 review	TV4 review	TV5 review
4, 8, 12	TV5	TV1	TV2	TV3	TV4

Mẫu báo cáo tuần (`docs/weekly/week-NN.md`):

```
# Tuần NN (dd/mm–dd/mm) — <mục tiêu>
## Kết quả chính
-
## Từng thành viên
| Thành viên | Đã làm (link PR) | Giờ | Tuần sau |
| --- | --- | --- | --- |
## Khó khăn & cách xử lý
## Số đo / ảnh chụp
## Kế hoạch tuần sau
```

Phần "Khó khăn & cách xử lý" mỗi tuần là nguyên liệu thô cho 11 bài lessons learned cuối kỳ — ghi ngay khi gặp.

7. Rủi ro, báo cáo và bảo vệ

Phạm vi 3 mức — rủi ro lớn nhất là ôm nhiều rồi làm hời hợt:

Mức	Nội dung	Khi nào bỏ
Phải có	Kafka, HDFS, Cassandra, Spark batch + streaming trên K8s; toàn bộ checklist Spark của thầy; đối soát Lambda; 11 lessons learned	Không bao giờ
Nên có	Trino + Superset, Redis top-K, bơm lỗi, benchmark tuần 9, chaos tuần 10, bảo mật, CI	Chỉ thu hẹp số thí nghiệm
Điểm cộng	Iceberg thay Parquet thuần, so sánh thực nghiệm Lambda vs Kappa, API có HPA, demo trên cloud	Bỏ đầu tiên nếu trễ

Rủi ro chính:

Rủi ro	Khả năng	Phòng tránh / dự phòng	Người theo dõi
Laptop thiếu RAM cho cả stack	Cao	k3s ghép 2–3 máy; giảm heap Kafka/Cassandra còn 512 MB–1 GB; bật Airflow/Superset theo nhu cầu	TV1

Rủi ro	Khả năng	Phòng tránh / dự phòng	Người theo dõi
Dựng Kafka/HDFS trên K8s kéo dài	Trung bình	Giới hạn cứng đến hết tuần 2; dùng Strimzi và image Hadoop có sẵn; TV3–TV5 hỗ trợ	TV1
Mạng giữa các laptop chập chờn lúc bảo vệ	Trung bình	Video demo dự phòng; cấu hình kind 1 máy với dữ liệu nhỏ	TV4
Kết quả ML thấp (dữ liệu thưa)	Trung bình	Luôn so với baseline "phổ biến nhất"; điểm năm ở quy trình đánh giá trung thực	TV4
Không tải đủ 7 tháng dữ liệu	Thấp	Bản Kaggle 2 tháng (~110 triệu dòng) vẫn đủ lớn	TV2
Một thành viên chậm	Trung bình	Cặp dự phòng (mục 4), board công khai, báo trượt vào Thứ Năm	Scrum master tuần đó

Báo cáo cuối kỳ theo 4 phần thầy yêu cầu, mỗi phần có người chịu trách nhiệm chính:

Phần	Nội dung	Người viết chính
1	Bài toán và tính phù hợp Big Data	TV4
2	Kiến trúc và thiết kế	TV3
3	Chi tiết hiện thực (mã, cấu hình, triển khai, giám sát)	TV2 (batch), TV3 (stream), TV1 (hạ tầng), TV5 (serving, giám sát)
4	11 bài lessons learned	Theo bảng mục 4
Ghép, định dạng, xuất PDF		TV5

Mỗi bài lessons learned theo mẫu: vấn đề → các cách đã thử và đánh đổi → giải pháp cuối kèm số đo → bài học.

Kịch bản demo 10 phút khi bảo vệ:

1. (1′) `kubectl get pods`: cụm nhiều node đang chạy đủ dịch vụ — TV1.
2. (2′) Bật replayer chế độ flash sale; Grafana hiện KPI từng phút và top sản phẩm hot — TV3.
3. (2′) Cảnh báo bỏ giỏ xuất hiện; gọi API gợi ý cho một user — TV5.
4. (2′) Kill một broker Kafka và driver streaming; hệ thống tự hồi phục, số đếm vẫn khớp — TV3 + TV1.

5. (2′) Superset: view Lambda hợp nhất, bảng đối soát speed vs batch — TV4 + TV2.
6. (1′) Truy vấn Trino liên nguồn HDFS + Cassandra với EXPLAIN ANALYZE — TV5.

Câu hỏi phản biện (ai cũng phải trả lời được):

- Vì sao Lambda mà không phải Kappa, khi Kafka có thể phát lại toàn bộ lịch sử?
- Cassandra là AP hay CP? Với RF=3, chọn R và W thế nào để đọc luôn thấy bản ghi mới nhất?
- Exactly-once của nhóm đạt được nhờ những thành phần nào? Nếu sink không idempotent thì sao?
- Vì sao Parquet cho lake nhưng Avro cho Kafka?
- Watermark 10 phút có nghĩa gì với bộ nhớ state và với sự kiện đến trễ 11 phút?
- Broadcast join khi nào gây hại? Ngưỡng `autoBroadcastJoinThreshold` nhóm đặt bao nhiêu, vì sao?
- MapReduce chậm hơn Spark bao nhiêu lần trên bài của nhóm, và vì sao?

Kế hoạch 4 người trước đây (tham khảo): ShopPulse — Kế hoạch BTL.